

Pemodelan Konsumsi Bahan Bakar Gabungan Kendaraan Menggunakan Multiple Linear Regression dengan One-Hot Encoding

Modeling Combined Vehicle Fuel Consumption Using Multiple Linear Regression with One-Hot Encoding

Rei Putra Soemanto, Amadeus Eugene Dirgantara, Jason Tio

NIM: 0706012410060, 0706012410063, 0706012410006

Program Studi Informatika, Universitas Ciputra, Surabaya, Jawa Timur, Indonesia

ALP Statistics and Probability

Abstrak

- Memodelkan konsumsi bahan bakar gabungan (comb_1_100km) dari spesifikasi kendaraan
 - Dataset Fuel Consumption 2000 sampai 2022, 22.555 baris setelah pembersihan
 - Metode multiple linear regression dengan one-hot encoding, diestimasi OLS
 - Tahun model dibuang, jumlah silinder dipertahankan karena ablasi membuktikan manfaatnya
 - Suku kuadratik tidak menaikkan R-squared uji sehingga model linear dipilih
 - Model menjelaskan sekitar 84 persen variansi dengan RMSE uji sekitar 1,18 L/100 km
 - Heteroskedastisitas dan non-normalitas ditangani dengan standard error robust HC3
-
- Kata kunci. multiple linear regression, one-hot encoding, seleksi fitur, multikolinieritas, heteroskedastisitas, standard error robust HC3

1. Pendahuluan

- Konsumsi bahan bakar berkaitan langsung dengan biaya, emisi, dan keberlanjutan
- Memprediksinya dari spesifikasi kendaraan bermanfaat untuk armada dan konsumen
- Karakteristik kendaraan bercampur antara besaran numerik dan kategori

kategori diolah menjadi kolom indikator melalui one-hot encoding

- Tantangan utama dalam pemodelan ini

multikolinieritas antara ukuran mesin dan jumlah silinder

prediktor hampir tidak relevan seperti tahun model

bentuk hubungan yang mungkin melengkung

pemenuhan asumsi Ordinary Least Squares

Pertanyaan Penelitian

- Pertama, fitur kendaraan mana yang sebaiknya dipertahankan sebagai prediktor
- Kedua, bagaimana variabel kategori diolah tanpa menimbulkan kolinieritas sempurna
- Ketiga, apakah model linear sudah memadai atau perlu suku polinomial
- Keempat, apakah model akhir memenuhi asumsi OLS dan bagaimana menangani pelanggarannya

2. Tinjauan Pustaka

- Multiple linear regression memodelkan respons sebagai jumlah kontribusi linear tiap prediktor
- One-hot encoding membuat k dikurang satu kolom indikator dengan satu kategori acuan
penetapan acuan menghindari dummy variable trap
- Pearson mengukur hubungan linear, Spearman mengukur hubungan monoton pada peringkat
- Multikolinieritas membesarkan standard error namun tidak selalu menurunkan daya prediksi
- Asumsi OLS diuji dengan Breusch-Pagan dan Jarque-Bera serta diagnostik visual
standard error robust HC3 dipakai saat ada heteroskedastisitas

3. Metode: Dataset dan Variabel

Variabel	Tipe	Peran	Catatan
Ukuran mesin	Numerik	Prediktor	Kontinu, 0,8 sampai 8,4 L
Jumlah silinder	Numerik	Prediktor	Umumnya 4, 6, 8
Tahun model	Numerik	Dibuang (korelasi nol)	Model 2000 sampai 2022
Jumlah gigi	Numerik	Prediktor	Nol untuk CVT sampai 10
Jenis bahan bakar	Kategori	Prediktor (one-hot)	5 jenis yaitu Regular gasoline (X), Premium gasoline (Z), Ethanol E85 (E), Diesel (D), Natural Gas (N)
Kelas kendaraan	Kategori	Prediktor (one-hot)	17 kelas (dirapikan)
Tipe transmisi	Kategori	Prediktor (one-hot)	5 tipe yaitu Automatic (A), Automatic with select shift (AS), Manual (M), Continuosly Variable Transmission atau CVT (AV), Automated Manual (AM)
comb_l_100km	Target	Respons	L/100 km

3. Metode: Persiapan Data dan Kerangka Analisis

- Tidak ada nilai hilang, satu baris duplikat dihapus sehingga tersisa 22.555 baris
 - Kelas kendaraan diseragamkan dari 32 menjadi 17 kelas
 - Transmisi dipecah menjadi tipe transmisi dan jumlah gigi (CVT diberi nol gigi)
 - Data dibagi 80 berbanding 20 menjadi 18.044 latih dan 4.511 uji
-
- Tahap 1 eksplorasi data
 - Tahap 2 seleksi fitur berbasis korelasi dan uji ablasi
 - Tahap 3 pembentukan model (one-hot, split, linear vs polinomial)
 - Tahap 4 validasi asumsi (Breusch-Pagan dan Jarque-Bera)
 - Tahap 5 penyempurnaan inferensi dengan standard error robust HC3


4.1 Statistik Deskriptif

Tabel 1. Statistik deskriptif variabel numerik (n = 22.555)

Variabel	Mean	Std	Min	Q1	Median	Q3	Max
Ukuran mesin (L)	3,357	1,335	0,8	2,3	3,0	4,2	8,4
Jumlah silinder	5,854	1,820	2	4	6	8	16
Tahun model	2011,6	6,298	2000	2006	2012	2017	2022
Jumlah gigi	5,635	1,957	0	5	6	6	10
comb_1_100km	11,034	2,911	3,6	9,1	10,6	12,7	26,1

- Ukuran mesin median 3,0 L, silinder terpusat di 4, 6, dan 8
- Respons condong ke kanan dengan ekor melampaui 20 L/100 km

4.2 Eksplorasi Visual: Pair Plot




Gambar 1. Pair plot variabel numerik (sampel acak 3.000 baris)


- Ukuran mesin, jumlah silinder, dan konsumsi menanjak jelas bersama
- Jumlah silinder dan jumlah gigi diskret sehingga membentuk pola vertikal
- Tahun model hampir datar terhadap konsumsi
- Hubungan dengan respons mendekati garis lurus

mendukung pemakaian model linear


4.2 Eksplorasi Visual: Boxplot per Kategori



Gambar 3. Konsumsi menurut kelas kendaraan




Gambar 2. menurut jenis bahan bakar



Gambar 4. menurut tipe transmisi

- Median konsumsi bergeser sistematis antar kategori
- Diesel paling hemat, Ethanol E85 dan Natural gas paling boros
- Kelas menanjak dari sedan kecil ke van dan pikap

4.3 Korelasi dan Seleksi Fitur



Gambar A1. Matriks korelasi Pearson

Tabel 2. Korelasi prediktor numerik

Pasangan	Pearson	Spearman	Putusan
Ukuran mesin ~ respons	0,807	0,845	Berarti
Jumlah silinder ~ respons	0,772	0,818	Berarti
Tahun model ~ respons	-0,068	-0,073	Dapat diabaikan
Ukuran mesin ~ silinder	0,913	0,936	Kolinier

- Putusan dari selang kepercayaan 95 persen terhadap ambang 0,1
- Pada n besar p-value hampir selalu signifikan sehingga tidak dipakai
- Selisih Spearman dan Pearson kecil sehingga model linear wajar

4.3 Keputusan Seleksi Fitur

Tabel 3. Keputusan seleksi fitur		
Prediktor	Keputusan	Alasan ringkas
Ukuran mesin	Pertahankan	Korelasi paling kuat dengan respons
Jumlah silinder	Pertahankan	Kolinier namun terbukti menambah prediksi (ablasi)
Tahun model	Buang	Korelasi dengan respons dapat diabaikan
Jumlah gigi	Pertahankan	Transmisi berkaitan dengan konsumsi
Jenis bahan bakar	Pertahankan	Median konsumsi bergeser antar kategori
Kelas kendaraan	Pertahankan	Median konsumsi bergeser antar kategori
Tipe transmisi	Pertahankan	Median konsumsi bergeser antar kategori

4.4 Pembentukan Model dan Pemilihan Bentuk

Tabel 4. Perbandingan model linear dan polinomial

Model	Jumlah parameter	R-squared latih	R-squared uji
Linear	28	0,8342	0,8365
Polinomial (ukuran mesin kuadratik)	29	0,8344	0,8364

- Pada data uji kedua model praktis setara padahal polinomial satu parameter lebih
 - Tambahan suku kuadratik tidak menaikkan kemampuan generalisasi
- model linear yang lebih sederhana dipilih (parsimoni)*

4.5 Model Final dan Koefisien

Cuplikan. Standard error, p-value, dan CI 95 persen berbasis HC3. Tabel penuh ada di paper

Tabel 5. Koefisien model linear final dengan standard error robust HC3					
Variabel (vs kategori acuan)	Koef	SE (HC3)	p-value	CI bawah	CI atas
Ukuran mesin	0,6438	0,0264	<0,001	0,592	0,696
Jumlah silinder	0,5740	0,0185	<0,001	0,538	0,610
Jumlah gigi	-0,0518	0,0075	<0,001	-0,066	-0,037
Bahan bakar: Ethanol E85 (E)	5,4887	0,0758	<0,001	5,340	5,637
Bahan bakar: Natural gas (N)	3,7854	0,2542	<0,001	3,287	4,284
Bahan bakar: Premium gasoline (Z)	2,0951	0,0574	<0,001	1,983	2,208
Bahan bakar: Regular gasoline (X)	1,4221	0,0569	<0,001	1,311	1,534
Transmisi: Continuously variable (AV)	-1,6222	0,0646	<0,001	-1,749	-1,496
Kelas: Van passenger	3,9195	0,1053	<0,001	3,713	4,126
Kelas: Van cargo	2,6157	0,0718	<0,001	2,475	2,757
Kelas: SUV	1,5188	0,0365	<0,001	1,447	1,590
Kelas: Minicompact	-0,1952	0,0441	<0,001	-0,282	-0,109

4.5 Interpretasi Koefisien


- Ukuran mesin dan jumlah silinder positif sehingga mesin lebih besar lebih boros
keduanya dibaca bersama sebagai ukuran kapasitas mesin
- Jumlah gigi negatif sehingga lebih banyak rasio gigi cenderung lebih hemat
- Diesel paling hemat sebagai acuan, Ethanol E85 paling boros
- Transmisi variabel kontinu paling hemat antar tipe transmisi
- Kelas kendaraan menanjak dari mobil kecil sampai van dan pikap
kelas Full size dan Mid size tidak berbeda nyata dari acuan Compact

4.6 Validasi Asumsi

Tabel 6. Hasil uji asumsi dan magnitudo penyimpangan

Aspek	Uji dan magnitudo	Pembacaan
Homoskedastisitas	Breusch-Pagan, R-squared aux 0,083	Heteroskedastik ringan sampai sedang
Normalitas (kemiringan)	Skewness 0,42	Kemiringan dapat diabaikan
Normalitas (ekor)	Excess kurtosis 2,14	Ekor lebih tebal dari normal

- Pada n besar uji formal selalu menolak sehingga dibaca dari magnitudo
- Heteroskedastisitas ditangani standard error robust HC3
- Inferensi koefisien tetap aman berkat Central Limit Theorem



Gambar 5. Q-Q plot (kiri) dan residual vs fitted (kanan)

4.6 Penyempurnaan Inferensi HC3

Tabel 7. Perbandingan standard error klasik dan HC3 (sampel koefisien)

Koefisien (sampel)	SE klasik	SE HC3	Rasio HC3 / klasik
Ukuran mesin	0,0185	0,0264	1,43
Jumlah silinder	0,0131	0,0185	1,41
Bahan bakar: Premium gasoline (Z)	0,0782	0,0574	0,73
Kelas: Van passenger	0,0859	0,1053	1,23

- Estimasi titik koefisien tidak berubah, hanya ketidakpastiannya dikoreksi
- Standard error ukuran mesin dan jumlah silinder naik sekitar 40 persen
bukti standard error klasik kurang tepat saat ada heteroskedastisitas
- HC3 dipilih karena paling konservatif

4.7 Ablasi dan Evaluasi Generalisasi

Tabel 8. Evaluasi generalisasi model final

Metrik	Latih	Uji	Selisih (latih dikurang uji)
R-squared	0,8342	0,8365	-0,0023
RMSE (L/100 km)	1,1857	1,1757	0,0101
MAE (L/100 km)	0,8962	0,8941	0,0020

- Membuang jumlah silinder menurunkan R-squared uji sekitar 0,02
kolinier bukan berarti redundan sehingga dipertahankan
- Menambahkan kembali tahun model tidak mengubah R-squared uji (p sekitar 0,852)
- Selisih latih dan uji sangat kecil sehingga tidak ada overfitting

5. Kesimpulan

- Model menjelaskan sekitar 84 persen variansi konsumsi dan menggeneralisasi dengan baik
- Penggerak utama adalah jenis bahan bakar, kelas kendaraan, dan ukuran mesin
- Jumlah silinder dipertahankan karena ablasi membuktikan ia menambah daya prediksi
- Tahun model dibuang karena korelasi dan kontribusinya dapat diabaikan
- Suku kuadratik tidak diperlukan sehingga model linear yang dipilih
- Heteroskedastisitas dikoreksi dengan standard error robust HC3

Keterbatasan, Saran, dan Sumber Data

- Breusch-Pagan dan Jarque-Bera menolak homoskedastisitas dan normalitas secara formal
penolakan wajar pada sampel besar dan tidak membatalkan estimasi titik koefisien
- Interval prediksi kurang terkalibrasi di bagian ekor akibat ekor tebal
- Independensi tidak diuji sehingga kemungkinan korelasi dalam grup masih terbuka
- Model bersifat asosiatif, bukan kausal
- Saran: menambah prediktor lain, memakai standard error berbasis cluster, kalibrasi interval prediksi
- Sumber data: Yilmaz, Fuel Consumption 2000 sampai 2022, Kaggle